

Aprentatge Automàtic i Mineria de Dades (AAMD) GEI (2024-25)

Pràctica 2: Aprentatge no supervisat

Objectiu

Aplicar i comparar els resultats de sis tècniques diferents d'aprenentatge no supervisat:

- **Principal Component Analysis (PCA)**
- **t-distributed Neighbor Stochastic Embedding (t-SNE)**
- **k-means**
- **Agglomerative Hierarchical Clustering (AHC)**
- **Autoencoder**
- **Self-Organizing Maps (SOM)**

Dades

Les tècniques d'aprenentatge no supervisat s'han d'aplicar a dos conjunts de dades diferents:

1. `A2-synthetic.txt`:
 - a. Característiques: 4 variables, 1 classe
 - b. Patrons: 360
 - c. La Informació de "classe" no s'ha d'utilitzar en l'aprenentatge no supervisat, només per a identificar la classe de cada patró en els plots.
2. `A2-real.txt`:
 - a. Característiques: 5 variables, 1 localització, 1 classe
 - b. Patrons: 333
 - c. La Informació de "classe" no s'ha d'utilitzar en l'aprenentatge no supervisat, només per a identificar la classe de cada patró en els plots.
 - d. La informació de "localització" no s'ha d'utilitzar en l'aprenentatge no supervisat, però es pot utilitzar en els plots.

Tots dos conjunts de dades s'han tractat per a eliminar outliers, dades no físiques i dades incompletes.

Desenvolupament i lliurament

Aquesta pràctica es fa en grups de dos.

Heu de lliurar un únic "Jupyter notebook" que contingui tot el que es demana a continuació, estructurat en seccions i incloent totes les explicacions que siguin necessàries per a entendre el que s'està fent. El codi ha d'estar correctament comentat (evitar comentaris que siguin "obvis"). Podeu utilitzar Python, Julia o R, com preferiu, i us heu d'assegurar que funcionen correctament en els contenidors Docker que vam explicar a classe. El nom del notebook ha de ser del tipus:

- `A2-Group_X-Nom1_Cognom1-Nom2_Cognom2.ipynb`

Treball a fer

1. Lectura de les dades.
2. Pre-processament de les dades.
3. Aplicar sis tècniques d'aprenentatge no supervisat:
 - **PCA**: trobar i representar gràficament la projecció PCA en dues dimensions, utilitzant un color diferent per a cada classe, i fer un “scree plot” de la variància acumulada.
 - **t-SNE**: trobar i representar gràficament la projecció t-SNE en dues dimensions, utilitzant un color diferent per a cada classe. Provar amb diferents valors dels paràmetres (perplexity).
 - **k-means**: utilitzar k-means per a classificar els patrons en $k = 2, 3, \dots, K$ classes, i comparar les classes obtingudes amb les reals. Per a cada valor k , fer un scatter plot de les dades (utilitzant com a coordenades x i y les obtingudes amb PCA), amb color que indiqui cadascuna de les k classes.
 - **AHC**: utilitzar la matriu de distàncies Euclideanes per a calcular i representar gràficament els dendrograms corresponents als mètodes unweighted average (UPGMA) i complete linkage (CL), utilitzant un color diferent per a representar els patrons (fulles del dendrograma) de cada classe.
 - **Autoencoder**: entrenar autoencoders per a projectar les dades originals en dues dimensions i representar-les gràficament, utilitzant un color diferent per a cada classe. Expliciteu l'arquitectura i paràmetres d'entrenament dels autoencoders utilitzats.
 - **SOM**: utilitzar Self-Organizing Maps (SOM) per a visualitzar les dades, per a diferents valors dels paràmetres (topologia i mida del mapa, learning rate, funció de veïnatge, etc.). El SOM ha de tenir com a mínim 100 neurones. Utilitzeu visualitzacions del SOM com per exemple els heatmaps de la classe més representada en cada posició, o la u-matrix. Pel “millor” mapa, calculeu i representeu gràficament els component planes.